Lab2: Symbolic Execution

1 环境配置与 Z3

Z3 是微软开发的 SMT 求解器,被广泛使用。要使用 Z3 首先需要在 lab2 目录下启动命令行并输入./install_z3.sh安装 Z3 和必要的编程环境。此过程可能需要较长时间,你可以先阅读 Utah 大学提供的Z3 教程 或者 smt/z3 文件夹下面 examples/c++/example.cpp文件里的 C++ 示例程序。

我们在 smt 目录下提供了一个 Z3 的示例程序 (smt.cpp)。成功安装 Z3 后,在 smt 目录下打开命令行输入make来编译并运行示例程序查看效果。

2 目标

本次 lab 需要实现一个符号执行工具 MiniSEE, 其中 SEE 是 Symbolic Execution Engine 的缩写。本次 lab 的原理和课件上讲的完全相同。你需要实现 3 个函数,实现前两个函数可以通过 8 个测试用例,实现第 3 个函数可以通过剩下两个包含 if 语句的测试用例。

这3个函数都在 lab2.cpp 中,你如果想了解符号执行的流程,只需要理解 cfg.h, minisee.h, minisee.cpp 这3个文件,从 minisee.cpp 里面的 minisee 函数开始看。后面会详细介绍相关的数据结构和代码流程。

在 lab2 中,编译后会产生可执行文件 minisee,然后输入命令./minisee test/xxx.c,那么 minisee 会读取 xxx.c 的内容,把里面的函数用图结构存储起来,cfg.h 里面的 cfg_node 类就是图中的节点。之后这个图会传给 minisee.cpp 中的函数 minisee,正式开始符号执行,判断函数中的 assert 是否会报错。如果 assert 永远不报错,那么 minisee 输出 verified,否则输出反例,例如测试用例是 int func(int a, int b),那么 minisee 会依次输出 a 和 b 的值。

3 运行和提交

代码写完后在 lab2 目录下打开命令行输入make,就会生成可执行文件 minisee。输入 make run 就会批量运行 test 目录下的 10 个测试用例,结果会输出到 test/output.txt 中,10 个测试用例共有 11 行输出,因为 test10 中有两条可以走到 assert 语句的路径。若希望对单个测试用例进行测试,可以输入./minisee test/xxx.c,其中 xxx 是测试用例的名字,例如./minisee test/test1.c,结果会直接输出至命令行。

完成本 lab 后请在 lab2 目录下运行make handin 生成 lab2.zip, 然后上传到 canvas。 注意:请不要在 lab2.cpp 中调用任何输入输出操作,比如 scanf, printf 和各种文件操作。否则可能会产生误判。

4 任务

你需要实现 lab2.cpp 中的 3 个函数。

4.1 函数 mystoi

```
1 int mystoi(string s);
```

mystoi 需要把输入字符串 s 里的数字转成 int 类型返回。s 可能是 10 进制无符号整数、10 进制带符号整数或 16 进制整数,都在 32 位整数表示范围内。你可以通过调用 c++ 的某些已有库函数实现此功能,也可以自己手动进行转换。这个函数不需要考虑不合法的 s。

4.2 函数 copy_exp_tree

4.2.1 功能

```
1 exp_node* copy_exp_tree(exp_node* root);
```

函数的参数 root 指向一棵表达式树, copy_exp_tree 需要拷贝这棵树产生一棵全新的树, 然后返回新的树。exp_node 的定义在 cfg.h 中,表示表达式树的节点。如果 root 为 NULL,就返回 NULL;否则就生成一棵新的树,这棵树表示的表达式和 root 表示的完全一致,这棵树的所有节点都是 new 出来的,不可以复用 root 中的任何节点。

4.2.2 表达式树

```
//exp_var表示表达式中的变量,如a
  |//exp_num表示表达式中的int常数,如11
  //exp_op表示表达式中的操作符,如+,-,!=,>等,也包括一元操作符~
    等
  enum EXP_NODE_TYPE { exp_var, exp_num, exp_op };
5
6 //表达式树中的节点
7 //可以表示布尔类型表达式如a>3
  //也可以表示int类型表达式如a+b或者3
  class exp_node {
9
10
  public:
11
     //当前节点存储的数据类型,包括变量、常数和操作符
12
13
     EXP NODE TYPE type;
     //当前节点存储的数据
14
     //如果是变量就是"a"这样的变量名
15
     //如果是操作符就是"+"这样的操作符
16
     //如果是常数就是"11"这样的常数
17
```

```
18 string val;
19 //表达式树的左右节点
20 exp_node* child[2];
21 22 };
```

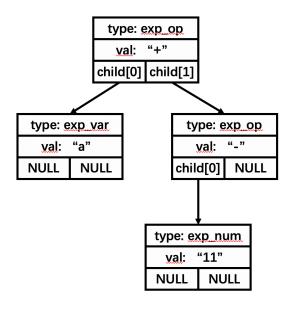


图 1: a+(-11) 对应的表达式树

表达式树由节点组成,节点的类定义如上,这个类各个字段的含义请参见注释,下面来看两个例子。a+(-11) 这种表达式对应的表达式树如图1。x==1 对应图2中的表达式树。

```
1 //输出表达式树root存储的表达式
void print_exp(exp_node* root);
```

你可以调用 print_exp 来输出一棵表达式树。这个函数可以用来 debug。

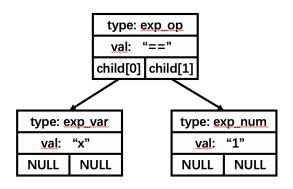


图 2: x==1 对应的表达式树

4.3 函数 analyze_if

— WARNING –

请完成前面两个函数再看本节。请确保你已掌握 symbolic execution 课件的内容。

完成前面两个函数后就可以通过前 8 个测试用例,他们都不包含 if 语句而且不需要特别理解符号执行的流程。

但是想要通过剩下 2 个包含 if 的测试用例,需要完成 lab2.cpp 中的函数 analyze_if。

5 数据结构和代码流程

下面先讲解 MiniSEE 的数据结构和执行流程。

5.1 程序控制流图 CFG

MiniSEE 从源文件中读取程序后会用程序流图 (control flow graph,CFG) 存储。程序流图是一个有向无环图,图中每个节点对应程序中的一条语句,节点 A 有边指向节点 B 表示执行完 A 语句后会执行 B 语句,如果某个节点对应 if 语句,那么这个节点会有两条出边,分别指向 if 条件为真和条件为假两种情况下的下一条语句。

每个节点用 cfg.h 中的数据结构 cfg_node 表示。

```
//cfg_assign表示赋值语句
  //cfg_if表示if语句
3 //cfg_assert表示assert语句
4 | //cfg_return表示return语句
  enum CFG_NODE_TYPE { cfg_assign, cfg_if, cfg_assert, cfg_return};
  1//控制流图中的节点,每个节点存一条语句
  class cfg node {
  public:
10
     //语句类型,包括赋值、assert、if、return
11
     CFG_NODE_TYPE type;
12
13
14
     //赋值语句中等号左边的变量名
     //如a = b+c, dst 就是"a"
15
     //如果是其他类型的语句则是空
16
     string dst;
17
18
19
     //如果是赋值语句, exp_tree存储等号右边的表达式
     //如果是return语句, exp_tree存储返回值对应的表达式
20
     //如果是if语句, exp_tree存储if条件对应的布尔类型表达式
```

```
//如果是assert语句, exp_tree存储assert的参数对应的表达式
22
     exp_node* exp_tree;
23
     //这条语句在源文件中的行号,在lab中用不到
24
     int lineno;
25
26
27
     //接下来要执行的语句
     //如果当前节点是assert、return、赋值语句,那么next[0]指向下一
28
        条语句, next[1]是NULL
     //如果当前节点是if语句,那么next[0]指向if条件为真要执行的指
29
        令, next [1] 指向 if 条件为假要执行的下一条指令
     //如果next [0] 和next [1] 都是NULL, 说明没有下一条语句了
30
     cfg_node* next[2];
31
32
  };
```

各个成员的含义参见注释。下面看一个例子,比如下面这段程序。

```
int func(int a, int x) {
    x = a + (-11)
    assert(x == 1);
4 }
```

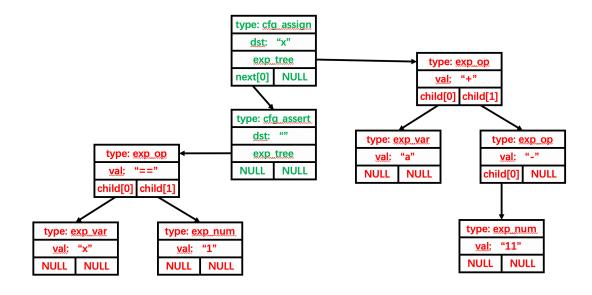


图 3:

对应的程序流图如图3所示,图中绿色的是 cfg 节点,红色的是各个 cfg 节点里面存储的 exp 节点。可以看到,这里没有 if, 所以每个节点都只有一条出边。因为是程序,有入口, 所以程序流图实际是有一个 root 节点的。

下面是一个有 if 语句的示例程序。

```
int func(int a, int b) {
    if(a > 0)
        a = -b;
    else
        b = 2;
    assert(a + b < 1);
}</pre>
```

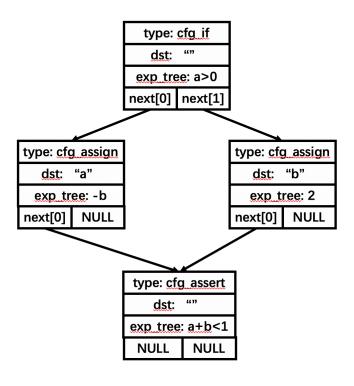


图 4:

它的 cfg 就如图4所示,此图省略了 exp_node。可以看到,if 语句对应的 cfg_node 有两条出边,左边的有向边指向条件为真时的语句,右边的有向边指向条件为假时的语句。

```
void print_cfg(cfg_node* root);
```

你可以调用 print_cfg 来输出一个程序流图,输出格式是把图转成源代码的形式输出。 这个函数可以用来 debug。

5.2 see_state

```
1 //see_state是当前符号执行节点的状态
2 //包括symbolic store, path constraint和next code
3 class see_state {
4 public:
```

```
//symbolic store, 是一个数组
5
      //每个变量在其中有一个表达式树exp_node*
6
7
      vector<exp_node*> sym_store;
      //path constraint
8
      //如果是NULL说明path constraint是true
9
10
      exp_node* path_const;
      //控制流图control flow graph(CFG)
11
      //表示接下来要执行的所有代码
12
      //cfg->root就指向符号执行节点中的next code,就是将要执行的代
13
         码
14
      cfg_node* cfg;
15
  };
```

回忆 symbolic execution 课件上的内容,符号执行会产生一棵树,MiniSEE 中用类 see_state 表示树中的每个节点,这个类在 minisee.h 文件中。和课件上讲的一样,类中有 3 个成员变量,对应课件上的 symbolic store, path constraint 和 next code,其中 next code 是一个 cfg_node 指针,指向一个程序流图,这个图中的第一个节点存储的就是将要执行的代码。

另外我们还需要知道程序中有哪些变量。

```
1 //存储所有局部变量的名字
2 extern vector<string> vartb;
3 //存储所有参数的名字
4 extern vector<string> inputtb;
```

这些 vector 被定义在 cfg.h 中,存储参数和局部变量的名字。每个测试用例中只有一个函数,所有数据都是 int 类型,没有全局变量。函数的参数和返回值都是 int 类型。

拿到一个 see_state 后,我们想知道每个变量现在的值是多少,于是有了下面这个 map, 在 minisee.cpp 中。

```
    //symbolic store是一个数组,每个变量对应其中一个元素
    //name_to_index存储了从变量名字到变量在symbolic store里面下标的映射
    //lab2中不涉及对name_to_index的操作
    static map<string, int> name_to_index;
```

这个 map 是从变量名(string)到数组 sym_store 下标(int)的映射。例如,我们拿到当前符号执行节点,节点里面的 symbolic storage 是数组 sym_store,那么参数 a 当前的值就是 sym_store[name_to_index["a"]] 表示的表达式树。因为符号执行中所有变量的值是用符号表达式表示的,所以 sym_store 是一个 exp_node* 类型的数组。

5.3 符号执行流程

这部分内容请配合 canvas 上的 lab2 视频讲解和 lab2 中的代码注释。

符号执行会生成一棵树,我们按照类似深度优先遍历的方法来访问每个节点。深度优先遍历需要下面这个栈来辅助。

- 1 //用于深度优先遍历符号执行树的栈
- 2 | stack<see_state> state_queue;

符号执行从 minisee.cpp 里面的 minisee 函数开始,输入是一个 cfg 表示的程序。

```
1 void minisee(cfg_node* cfg);
```

minisee 函数中首先调用 init_state 函数构造符号执行树的根结点,并把这个根结点压入栈 state_queue 中。之后 minisee 函数进入循环,每次取走栈顶的符号执行节点,然后调用 state_handler 函数处理它。

- 1 //state是当前符号执行节点
- 2 | //包括symbolic store, path constraint和next code
- 3 | void state_handler(see_state* state);

state_handler 函数会把这个节点中记录的 next code 拿出来,也就是 state->cfg,如果发现是 NULL 说明已经没有下一条代码了,直接返回。如果发现这条代码的类型 (state->cfg->type)是 return,说明程序结束,也直接返回。

如果发现是赋值语句,那么调用 analyze_assign 函数处理。

- 1 //处理赋值语句
- 2 │//当前state里面的cfg第一条指令是一条赋值语句
- 3 | void analyze_assign(see_state* state);

这个函数框架代码已经给出,不需要大家完成,所以这里只介绍大概流程。当前 state 是赋值语句对应的符号执行节点,这个函数会生成这个节点对应的子节点压入栈中。state 的 next code 是 state->cfg,按照之前对 see_state 类的讲解,子节点的 next code 应该是 state->cfg->child[0]。因为当前不是 if 语句,path constraint 没有变化,所以子节点的 path_const 和 state 里的 path_const 相同。赋值语句会修改 symbolic store,所以调用 update_sym_storage 得到子节点的 symbolic store。这样以来,子节点的 3 个数据成员就都有了,然后把子节点压入栈中,等待大循环的下一轮处理。

如果发现是 assert 语句,说明到了验证的时刻了。调用 verify 函数,框架代码已经实现,生成逻辑公式交给 SMT solver Z3 进行验证。

如果是 if 语句请看视频讲解。

5.4 analyze if 功能

```
1 | void analyze_if(see_state* state);
```

state 是符号执行树中当前走到的节点,在符号执行中,这个节点会有两个子节点,分别对应 if 条件成立和不成立的情况,函数功能是构造这两个子节点并把它们压入栈 state_queue中。实现这个函数需要调用 lab2.cpp 中的 update_path_const 函数构造新的 path constraint。